



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Escola Tècnica
Superior d'Enginyeria
Informàtica

Escola Tècnica Superior d'Enginyeria Informàtica
Universitat Politècnica de València

Evolución del Empleo ante la Inteligencia Artificial (2010-2025)

Proyecto de la asignatura

Proyecto I, Comprensión de datos

Grado en Ciencia de Datos

Autores: Claudia Carbó Mañes, Roger Cascant Rodrigo, Pau Giménez i Carbonell, Aarón Moya Gallo, Iñaki Navarro Madrid

Tutor: Vicent Giménez Alventosa

Curso 2025-26

Resumen

La Inteligencia Artificial (IA) está transformando de forma significativa la organización del trabajo, los perfiles profesionales demandados y las competencias requeridas en el mercado laboral. En este contexto, el presente proyecto analiza la evolución del empleo en relación con la expansión de la IA durante el periodo 2010-2025, con el objetivo de estudiar su asociación con los salarios ofertados, el riesgo de automatización, el nivel de experiencia profesional y la necesidad de capacitación profesional (*reskilling*).

La investigación se estructura en cuatro fases principales. En primer lugar, se realiza una revisión del estado del arte sobre el impacto económico y laboral de la IA, atendiendo especialmente a la automatización de tareas, la transformación de competencias y la posible existencia de una prima salarial asociada a las habilidades tecnológicas. En segundo lugar, se emplea un conjunto de datos público procedente de Kaggle, formado por registros de ofertas de empleo, salarios, sectores profesionales, niveles de experiencia y variables relacionadas con la adopción de IA.

Posteriormente, se lleva a cabo un proceso de preparación y limpieza de datos mediante Python, incluyendo el tratamiento de valores nulos, la detección de valores atípicos y la transformación de variables textuales relacionadas con habilidades de IA. A partir del conjunto de datos procesado, se realiza un análisis descriptivo y estadístico centrado en cuatro dimensiones: la relación entre intensidad de uso de IA y salario medio ofertado, la identificación de sectores con mayor riesgo de automatización, la comparación del riesgo de desplazamiento según el nivel de experiencia profesional y el análisis de la variable `reskilling_required`.

Los resultados muestran una asociación positiva entre la presencia de competencias de IA y el salario medio ofertado. Asimismo, se observan diferencias entre sectores en los niveles de riesgo de automatización. En cuanto al nivel de experiencia, la comparación realizada muestra diferencias limitadas, por lo que la posible mayor vulnerabilidad de los perfiles junior debe interpretarse como una hipótesis apoyada por la literatura, pero no confirmada de forma concluyente por los datos analizados. Además, en este dataset la variable de *reskilling* está directamente asociada a la mención de IA, por lo que debe interpretarse como un indicador derivado o altamente dependiente. En conjunto, los resultados deben entenderse como patrones

estadísticos observados dentro de la muestra analizada, no como relaciones causales directas ni como conclusiones generalizables a todo el mercado laboral.

Palabras clave: Inteligencia Artificial, mercado laboral, automatización, ciencia de datos, *reskilling*.

Contenido

1. Introducción	7
1.1 Motivación del trabajo	7
1.2 Objetivos	8
1.3 Metodología	9
1.4 Estructura del trabajo	10
2. Estado del arte	11
2.1 Crítica al estado del arte	11
2.2 Propuesta	12
3. Alcance del proyecto	13
3.1 Requisitos, restricciones e hipótesis	13
3.2 Productos entregables	15
3.3 Límites y criterios de éxito	15
3.4 Resultados del proyecto	22
3.5 Alineación con ODS	31
4. Calendario del proyecto	32
4.1 Diagrama de Gantt	32
4.2 Distribución de las tareas	36
5. Preparación y comprensión de datos	37
5.1 Conjunto de datos	37
5.2 Significado de los datos	38
5.3 Limpieza y transformación de datos	39
6. Conocimiento extraído	40
6.1 Metodología	40
6.2 Herramientas	41

6.3 Análisis de vulnerabilidad por nivel de experiencia	41
7. Validación y despliegue	43
7.1 Uso de otro conjunto de datos. Encuestas.	43
7.2 Repositorio reproducible	44
8. Conclusiones	45
9. Bibliografía	47
10. Anexos	47

1. Introducción

Este primer capítulo establece las bases y el contexto de nuestro estudio sobre la evolución del mercado laboral ante el impacto de la Inteligencia Artificial. A lo largo de estas páginas se detalla la motivación principal que ha impulsado la investigación, los objetivos generales y específicos que perseguimos, la metodología técnica empleada para analizar los datos y, por último, la estructura general que guiará el resto de esta memoria.

1.1 Motivación del trabajo

ACTA DE CONSTITUCIÓN DEL PROYECTO

- **Nombre del Proyecto:** Evolución de la IA (2010-2025) sobre el empleo.
- **Asignatura:** Proyecto I: Comprensión de datos (Grado en Ciencia de Datos).
- **Grupo:** 1B1.
- **Profesor de la asignatura:** Vicent Vicent Giménez Alventosa
- **Tutor de la memoria:** Vicent Giménez Alventosa.
- **Equipo de Proyecto:** Claudia (Líder / Project Manager), Aarón (Data Scientist), Pau, Roger e Iñaki.

Justificación y Oportunidad de Investigación

La transformación del mercado laboral bajo la influencia de la Inteligencia Artificial (IA) entre los años 2010 y 2025 constituye uno de los fenómenos socioeconómicos más complejos y acelerados de la era moderna. El presente proyecto nace como una oportunidad de investigación ante la necesidad de decodificar empíricamente, a través de la ciencia de datos, cómo esta disrupción tecnológica no solo altera la productividad empresarial, sino que redefine la relación entre el capital humano y la tecnología.

Misión del Proyecto

La misión fundamental de este proyecto es analizar cómo la inteligencia artificial está influyendo en el mercado laboral mundial a lo largo del periodo

2010-2025. A partir de la extracción, limpieza y análisis de un gran volumen de datos (*dataset* de Kaggle), el objetivo es analizar la relación estadística entre la adopción de IA, las estructuras salariales, el riesgo de automatización y la necesidad de adquisición de nuevas competencias

Autorización Formal

Mediante el presente documento queda oficialmente autorizado el inicio del proyecto. Todos los miembros del equipo mencionados anteriormente se comprometen a destinar el esfuerzo, el rigor analítico y los recursos necesarios para cumplir con los objetivos SMART fijados, respetar los límites del alcance y lograr la entrega final de los productos acordados.

Aprobación y Firmas del Equipo (Grupo 1B1):

- *Firma de la Project Manager:* Claudia _____
- *Firma del Data Scientist:* Aarón _____
- *Firma del Equipo Analista:* Pau _____, Roger _____, Iñaki _____
- *Fecha de autorización:* 20 de Enero de 2026

1.2 Objetivos

Para llevar a cabo la misión de este proyecto con rigor analítico, se ha establecido un objetivo general que define la meta global de la investigación, el cual se desglosa posteriormente en cuatro objetivos específicos diseñados bajo la metodología SMART (Específicos, Medibles, Asignables, Realistas y Temporales) para garantizar su correcto seguimiento y ejecución.

Objetivo General

El objetivo general del proyecto es estudiar la relación entre la presencia de Inteligencia Artificial y la evolución de distintas variables del empleo, como salarios, riesgo de automatización y transformación de competencias técnicas

Objetivos Específicos

Para alcanzar el objetivo general, el equipo de trabajo se ha marcado las siguientes metas técnicas y temporales:

- **Evolución y "Prima Salarial":** Analizar cómo ha cambiado la intensidad de uso de inteligencia artificial (`ai_intensity_score`) en los empleos entre 2010 y 2025 y comprobar estadísticamente si existe relación con el salario medio (`salary_usd`), obteniendo resultados medibles antes de la entrega final del proyecto.
- **Riesgo Sectorial:** Identificar qué sectores industriales tienen un mayor riesgo de automatización (`automation_risk_score`) —considerando como "alto riesgo" aquellos que superan el umbral de 0,7— y calcular qué porcentaje exacto representan sobre el total de la muestra durante la fase de análisis.
- **Vulnerabilidad por Experiencia:** Comparar la distribución del riesgo de desplazamiento por IA (`ai_job_displacement_risk`) entre los distintos niveles de experiencia profesional (`seniority_level`), con el fin de analizar si existen diferencias relevantes entre perfiles junior, mid, senior, lead, intern y executive. Este análisis se interpretará de forma prudente, teniendo en cuenta que la variable `ai_job_displacement_risk` es categórica y que su relación con `automation_risk_score` debe comprobarse empíricamente antes de extraer conclusiones sobre vulnerabilidad laboral.
- **Adaptación y Recapacitación:** Calcular qué porcentaje de empleos requiere recapacitación profesional obligatoria (*reskilling*) en los sectores con mayor adopción de IA (`reskilling_required = True`) y analizar la curva de evolución temporal de esta necesidad entre 2010 y 2025, de cara a incluirlos en el informe final.

1.3 Metodología

La metodología empleada en este proyecto sigue el ciclo de vida estándar de un análisis de Ciencia de Datos, abarcando desde la recolección de la información hasta la extracción de conocimiento. El proceso se ha estructurado en las siguientes fases principales:

1. **Extracción y recopilación:** El estudio parte de la obtención del conjunto de datos `ai_impact_jobs_2010_2025.csv` extraído de la plataforma pública Kaggle,

el cual contiene registros detallados sobre ofertas de empleo, salarios y requerimientos de IA a nivel global.

2. **Preparación y limpieza de datos:** Utilizando el lenguaje de programación Python (mediante las librerías pandas y numpy), se ha llevado a cabo un riguroso proceso de limpieza. Este incluyó la eliminación de registros duplicados, el tratamiento de valores nulos (imputando salarios mediante la mediana sectorial) y la exclusión de valores atípicos (*outliers*) aplicando el método del Rango Intercuartílico (IQR) para evitar distorsiones estadísticas.
3. **Transformación de variables complejas:** Para el análisis de habilidades técnicas (columna *ai_skills*), se aplicaron técnicas de separación de cadenas de texto (*split* y *explode*) que permitieron aislar y contabilizar competencias individuales como *Machine Learning*, *NLP* o *MLOps*.
4. **Análisis y extracción de conocimiento:** A partir del *dataset* limpio, se ha procedido a realizar un análisis descriptivo y estadístico para correlacionar variables clave (como la intensidad de IA frente a los salarios) y visualizar la evolución temporal de la necesidad de capacitación profesional (*reskilling*).

(Nota: El detalle técnico de las transformaciones y el código específico desarrollado se documentan exhaustivamente en los apartados 5 y 6 de esta misma memoria).

1.4 Estructura del trabajo

Para facilitar la lectura y comprensión de este proyecto, la presente memoria se ha organizado de forma secuencial abarcando desde la concepción teórica hasta el análisis técnico de los datos. Tras este primer capítulo de **Introducción**, el documento se divide en los siguientes apartados:

- **Capítulo 2. Estado del arte:** Analiza el marco teórico, las investigaciones previas y la literatura económica actual sobre el impacto de la IA en el mercado laboral, justificando la pertinencia de nuestra propuesta.
- **Capítulo 3. Alcance del proyecto:** Define exhaustivamente los requisitos, restricciones, límites y criterios de éxito del proyecto, incluyendo además la Estructura de Desglose del Trabajo (EDT) y sus entregables.

- **Capítulo 4. Calendario del proyecto:** Presenta la distribución temporal de las tareas mediante el diagrama de Gantt, justificando los plazos a través de estimaciones matemáticas y el cálculo de la ruta crítica.
- **Capítulo 5. Preparación y comprensión de datos:** Detalla el origen del conjunto de datos utilizado y documenta todo el proceso técnico de limpieza y transformación de las variables.
- **Capítulo 6. Conocimiento extraído:** Expone la metodología y las herramientas empleadas para llevar a cabo el análisis estadístico, mostrando los resultados obtenidos sobre salarios, riesgo de automatización y capacitación profesional.
- **Capítulo 7. Validación y despliegue:** Describe los *scripts* de programación desarrollados para el estudio y proporciona el enlace al repositorio público donde se aloja el código.
- **Capítulo 8. Conclusiones:** Resume los hallazgos finales del proyecto, verificando el cumplimiento de los objetivos y conectando los datos con la teoría.

Finalmente, el documento se cierra con el **Capítulo 9. Bibliografía**, donde se referencian todas las fuentes consultadas bajo las normas APA, y el **Capítulo 10. Anexos**, que contiene información y documentación técnica complementaria

2. Estado del arte

Este capítulo presenta una revisión exhaustiva de la literatura académica, los informes institucionales y los estudios económicos recientes que abordan el impacto de la Inteligencia Artificial en el mercado laboral. En las siguientes páginas se examinan críticamente las principales corrientes teóricas sobre el riesgo de automatización, la transformación de las competencias profesionales y la reestructuración salarial, culminando en la propuesta técnica y analítica que fundamenta la presente investigación.

2.1 Crítica al estado del arte

El análisis de la literatura académica muestra una clara evolución en la forma de interpretar el impacto de la Inteligencia Artificial (IA) sobre el empleo. En los primeros estudios, predominaba una visión centrada en el riesgo de automatización. En este sentido, Frey y Osborne estimaron que el 47 % del empleo en Estados Unidos presentaba un alto riesgo de automatización (Frey & Osborne, 2013).

Sin embargo, los estudios más recientes matizan esta perspectiva y no plantean necesariamente una destrucción masiva de puestos de trabajo. El Fondo Monetario Internacional señala que aproximadamente el 40 % del empleo mundial está expuesto a la IA, aunque dicha exposición puede traducirse tanto en sustitución como en complementariedad de tareas (FMI, 2024).

Para entender esta transformación, se utiliza el enfoque basado en tareas desarrollado por Acemoglu y Autor, según el cual el efecto de la tecnología sobre el empleo debe analizarse a través de las tareas que componen cada ocupación, y no únicamente a partir de profesiones completas (Acemoglu & Autor, 2011). Desde esta perspectiva, la IA puede automatizar determinadas tareas, pero también complementar otras actividades humanas. En trabajos posteriores, Acemoglu, Autor y Johnson plantean el concepto de “IA pro-trabajador”, entendido como el diseño de sistemas de IA orientados a ampliar las capacidades humanas, la productividad y el valor del juicio experto de las personas trabajadoras (Acemoglu, Autor & Johnson, 2026).

Por otro lado, la literatura reciente también identifica efectos desiguales en función del perfil profesional. En relación con la denominada prima salarial, PwC indica que los perfiles con competencias en IA pueden percibir salarios hasta un 56 % superiores respecto a perfiles comparables sin dichas competencias (PwC, 2025).

Asimismo, algunos estudios advierten de una mayor exposición de los perfiles de entrada. Brynjolfsson, Chandar y Chen, en el informe *Canaries in the Coal Mine? Six Facts about the Recent Employment Effects of Artificial Intelligence*, señalan que los trabajadores de entre 22 y 25 años en las ocupaciones más expuestas a la IA generativa experimentaron un descenso relativo del 16 % en el empleo, incluso tras controlar por efectos a nivel de empresa (Brynjolfsson, Chandar & Chen, 2025). Esta evidencia debe interpretarse como un resultado referido al mercado laboral estadounidense y a ocupaciones altamente expuestas, no como una conclusión universal sobre todos los perfiles junior.

Finalmente, el Foro Económico Mundial estima que el 39 % de las competencias laborales cambiarán de forma significativa antes de 2030, lo que refuerza la importancia del reciclaje profesional o *reskilling* (Foro Económico Mundial, 2025).

2.2 Propuesta

A partir de la revisión teórica anterior, la propuesta de este proyecto consiste en explorar si las tendencias descritas en la literatura aparecen también en la muestra analizada. Para ello, se plantea realizar un análisis exploratorio de un conjunto de

datos público sobre ofertas de empleo relacionadas con la Inteligencia Artificial durante el periodo comprendido entre 2010 y 2025.

El conjunto de datos seleccionado procede de la plataforma Kaggle e incluye registros sobre ofertas de empleo, salarios, sectores profesionales, niveles de experiencia y competencias tecnológicas. Mediante el lenguaje de programación Python, se realizará un proceso de limpieza, transformación y análisis estadístico descriptivo con el fin de identificar patrones dentro de la muestra disponible.

En concreto, la investigación se centrará en cuatro aspectos principales:

1. **Prima salarial asociada a la IA:** analizar estadísticamente si existe una asociación entre la intensidad de uso de IA en una oferta de empleo y el salario medio ofertado.
2. **Riesgo sectorial de automatización:** identificar qué sectores presentan mayores valores de `automation_risk_score` dentro de la muestra, considerando como referencia de alto riesgo aquellas observaciones que superen el umbral de 0,7.
3. **Diferencias por nivel de experiencia:** analizar si la muestra presenta diferencias de riesgo entre niveles de experiencia profesional, interpretando los resultados de forma prudente y teniendo en cuenta las limitaciones de las variables disponibles.
4. **Recapacitación profesional (*reskilling*):** estudiar la distribución de la variable `reskilling_required` en el conjunto de datos, considerando que su interpretación debe realizarse con cautela si está directamente asociada a otras variables relacionadas con la mención de IA.

Con esta propuesta, se busca aportar un análisis cuantitativo y exploratorio que complemente la literatura revisada, sin pretender establecer relaciones causales ni generalizar los resultados al conjunto del mercado laboral mundial. Las conclusiones se limitarán a los patrones observados en la muestra analizada y a las restricciones metodológicas del dataset utilizado.

3. Alcance del proyecto

Este capítulo define de forma precisa los límites y características de nuestro proyecto. En primer lugar, establecemos los requisitos y las restricciones que guían el trabajo. A continuación, detallamos los entregables previstos y los criterios que determinarán el éxito del estudio. Finalmente, incluimos la Estructura de Desglose del Trabajo (EDT) y alineamos nuestra investigación con los Objetivos de Desarrollo Sostenible (ODS).

3.1 Requisitos, restricciones e hipótesis

Para garantizar el éxito del proyecto, hemos definido nuestras necesidades técnicas mediante la metodología MoSCoW:

- **Obligatorios (*Must*):** Debemos cargar correctamente el conjunto de datos y gestionar los valores nulos. Calcularemos el salario medio por año y segmentaremos el riesgo de automatización por industria para identificar las cinco más vulnerables. Además, extraeremos las palabras clave sobre habilidades de IA.
- **Recomendables (*Should*):** Calcularemos la correlación estadística entre la intensidad de IA y los salarios. Generaremos gráficos de tendencia temporal y calcularemos el porcentaje exacto de empleos que exigen reciclaje profesional.
- **Deseables (*Could*):** Cruzaremos el nivel de riesgo con el tamaño de la empresa. También crearemos una nube de palabras visual con las habilidades técnicas más demandadas.
- **Opcionales (*Wish*):** No priorizaremos la predicción de salarios para 2030 ni la creación de una interfaz web interactiva, ya que quedan fuera del alcance principal.

El desarrollo del proyecto está sujeto a ciertas restricciones. Nuestra principal limitación es el tiempo asignado por el curso académico, lo que restringe la profundidad del estudio. Además, dependemos exclusivamente de información académica y datos publicados hasta 2025. Nuestro enfoque será puramente teórico y analítico, sin realizar encuestas propias ni trabajo de campo.

Finalmente, partimos de varias hipótesis fundamentales. Se asume que los registros utilizados son adecuados para realizar un análisis exploratorio sobre la evolución del empleo ante la IA entre 2010 y 2025. No obstante, el conjunto de datos no debe interpretarse como una muestra estadísticamente representativa del mercado laboral global. La información procede de una fuente pública y puede contener sesgos de cobertura por país, sector, tipo de oferta o disponibilidad de datos. Por tanto, los resultados obtenidos deben entenderse como patrones observados dentro de la muestra analizada, no como conclusiones generalizables a la totalidad del mercado laboral mundial. También suponemos que las variables temporales están completas y no contienen años sin registros.

3.2 Productos entregables

El ciclo de vida del proyecto generará cinco productos entregables principales. En primer lugar, presentaremos un informe de planificación y distribución del trabajo. En segundo lugar, entregaremos el conjunto de datos procesado y libre de valores atípicos. En tercer lugar, mostraremos un prototipo inicial para verificar el correcto desarrollo de nuestro código. Finalmente, elaboraremos esta memoria técnica detallada y realizaremos una presentación audiovisual para exponer nuestros resultados.

3.3 Límites y criterios de éxito

Este apartado define las exclusiones de nuestra investigación para evitar malentendidos sobre su alcance. También establece las métricas exactas para evaluar el cumplimiento de nuestros objetivos y la calidad del producto final.

Límites del proyecto

Para delimitar nuestro trabajo, establecemos las siguientes exclusiones. Nuestro estudio no analizará el empleo mundial de forma genérica, sino que priorizará los sectores con mayor volumen de trabajadores. No realizaremos predicciones teóricas sobre el futuro del empleo. Tampoco desarrollaremos aplicaciones tecnológicas de software. Finalmente, evitaremos abordar debates políticos sin una base estructurada y una conclusión razonada.

Otra limitación relevante se encuentra en la cobertura sectorial de la base procesada. Aunque el dataset original contiene una mayor variedad de industrias, la versión GOLD utilizada para parte del análisis conserva únicamente las industrias más frecuentes. Por tanto, el estudio prioriza la consistencia y estabilidad de los análisis sobre la cobertura completa de todos los sectores disponibles. Esta decisión metodológica limita la generalización de los resultados a industrias excluidas del análisis final, como Finance, Government, Education y Energy.


Criterios de éxito del proyecto

Consideraremos el proyecto exitoso si logramos cumplir todos los objetivos específicos SMART definidos inicialmente. Debemos abarcar el análisis completo de los datos comprendidos entre 2010 y 2025. Además, es un requisito indispensable cumplir al 100 % con las tareas obligatorias (categoría "Must") establecidas en la fase de diseño. Por último, el informe final debe presentar conclusiones claras, fundamentadas en datos y sin contradicciones.

Criterios de aceptación del producto

El producto final será aceptado si el informe incluye todos los análisis estadísticos solicitados. Los datos de origen deben estar limpios y procesados correctamente. Las visualizaciones gráficas del análisis deben resultar claras y comprensibles para el lector. En definitiva, nuestras conclusiones tienen que responder de manera directa a la misión fundacional del proyecto.

3.4 Resultados del proyecto



Diccionario de la EDT

Bloque 1: Gestión y Marco Administrativo

1.1. Redacción del Acta de Constitución del Proyecto	Redacción del documento formal que autoriza el inicio del proyecto, definiendo la misión y los objetivos de alto nivel.
Responsable	Claudia
Entregables	Documento "Acta de Constitución del Proyecto".
Hitos	Aprobación inicial del tutor para comenzar las fases técnicas.
Recursos necesarios	Plantillas de gestión, guía de la asignatura.
Estimación de plazos	2 sesiones

1.2. Definición de Requisitos (MoSCOW)	Identificación y priorización de las necesidades del proyecto (Must, Should, Could, Wish)
Responsable	Pau
Entregables	Documento con los requisitos ordenados por categorías y matriz de trazabilidad de requisitos
Hitos	Congelación del alcance para evitar "hacer más trabajo del estrictamente necesario".
Recursos necesarios	Presentaciones de clase
Estimación de plazos	2 sesiones

1.3. Elaboración de la EDT y Diccionario	Desglose jerárquico del trabajo en paquetes manejables y descripción detallada de cada uno
Responsable	Pau
Entregables	Diagrama de descomposición y Diccionario de la EDT
Hitos	Estructuración completa de todas las tareas del proyecto.

Recursos necesarios	Software de diagramación, metodología de gestión de proyectos (presentaciones poliformat)
Estimación de plazos	4 sesiones

Bloque 2: Planificación Temporal y de Recursos

2.1. Estimación PERT	Aplicación de la estimación de tres valores (optimista, pesimista y más probable) para calcular duraciones.
Responsable	Iñaki
Entregables	Tabla de duraciones estimadas y análisis de reservas
Hitos	Definición realista de los plazos de ejecución.
Recursos necesarios	Base de datos y técnicas estadísticas de estimación.
Estimación de plazos	2 sesiones

2.2. Diagrama de Precedencias	Creación del modelo lógico que muestra qué tareas deben terminar para que otras empiecen.
Responsable	Roger
Entregables	Diagrama de red del proyecto
Hitos	Visualización del flujo de trabajo secuencial y paralelo.
Recursos necesarios	Lista de tareas de la EDT y dependencias detectadas.
Estimación de plazos	1.5 sesiones

2.3. Cálculo de la Ruta Crítica y Holguras	Cálculo matemático del camino más largo y determinación de la flexibilidad (holgura) de cada tarea.
Responsable	Roger
Entregables	Tabla con fechas tempranas y tardías, y gráfico de ruta crítica.

Hitos	Identificación de tareas que bloquean la fecha de entrega final.
Recursos necesarios	Estimaciones de Iñaki y diagrama de precedencias.
Estimación de plazos	1.5 sesiones

Bloque 3: Marco Teórico e Investigación

3.1. Estado del Arte	Investigación crítica citando fuentes como el FMI, la OIT y PwC (2025) sobre el mercado laboral e IA
Responsable	Claudia
Entregables	Texto redactado para el capítulo 2 de la memoria.
Hitos	Justificación teórica del periodo de estudio 2010-2025.

Recursos necesarios	Informes, estudios sobre la ia en el mercado laboral, corrientes teóricas sobre el riesgo de la automatización
Estimación de plazos	2 sesiones

3.2. Propuesta conceptual: IA "Pro-Trabajador	Desarrollo conceptual basado en la perspectiva de tareas para abogar por una IA complementaria al humano
Responsable	Claudia
Entregables	Sección de conclusiones teóricas integradas en la memoria.
Hitos	Definición de la narrativa central del proyecto
Recursos necesarios	Artículos de foros especializados sobre el tema añadidos en la memoria
Estimación de plazos	2 sesiones

Bloque 4 Ingeniería y Análisis de Datos

4.1. Limpieza y tratamiento de nulos/outliers en Python	Procesamiento en Python: tratamiento de nulos, eliminación de outliers e imputación por mediana industrial
Responsable	Aaron
Entregables	Base de datos limpia y código de limpieza
Hitos	Obtención de una muestra representativa y fiable para el análisis
Recursos necesarios	Librerías pandas/numpy(jupyter notebook), dataset de Kaggle
Estimación de plazos	1 sesión

4.2. Ejecución de correlaciones estadísticas (IA vs Salario)	Cálculo estadístico (Pearson/Spearman) de la relación entre intensidad de IA y "prima salarial"
Responsable	Roger
Entregables	Gráficos de dispersión y validación de p-valores.

Hitos	Demostración numérica de la hipótesis sobre el impacto salarial de la IA.
Recursos necesarios	Código Python para análisis estadístico avanzado
Estimación de plazos	2 sesiones

4.3. Análisis cuantitativo de necesidades de <i>reskilling</i>	Cálculo del porcentaje exacto de empleos que requieren capacitación según las skills detectadas.
Responsable	Aaron
Entregables	Cifras comparativas alineadas con el Foro Económico Mundial.
Hitos	Cumplimiento del objetivo específico número 4 del proyecto
Recursos necesarios	Transformación <i>split/explode</i> de la columna <i>ai_skills</i> .
Estimación de plazos	3 sesiones

4.4 Análisis de las variables ai_intensity_score y automation_risk	Realizar análisis de las variables y llegar a conclusiones
Responsable	Iñaki y Pau
Entregables	Gráficos sobre las variables
Hitos	Contextualización de nuestro problema mediante gráficos
Recursos necesarios	Base de datos kaggle(limpiada por Aaron), Rstudio, jupyter notebook
Estimación de plazos	3 sesiones

Bloque 5: Consolidación y Entrega

5.1 Fusión de memoria final y bibliografía	Integración final de todos los capítulos y formateo correcto de la bibliografía según la rúbrica.
Responsable	Claudia
Entregables	Memoria final PDF lista para entrega

Hitos	Cierre de la documentación escrita del proyecto
Recursos necesarios	Marco teórico de Claudia y resultados técnicos de Aarón.
Estimación de plazos	6 sesiones

5.2. Creación de visualizaciones con citas integradas	Mejora de la presentación incluyendo referencias breves (ej. FMI 2024) en cada gráfico.
Responsable	Todos
Entregables	Presentación de Canva definitiva
Hitos	Alineación visual completa entre la teoría y los datos
Recursos necesarios	Gráficos generados en la fase 4 y bibliografía.
Estimación de plazos	4 sesiones

5.3. Redacción de guión y producción del vídeo	Redacción del storyboard y grabación de la presentación técnica por parte de todos los miembros
Responsable	Todos
Entregables	Vídeo de presentación y guion redactado.
Hitos	Entrega final del proyecto en el mes de mayo
Recursos necesarios	Diapositivas de Canva y herramientas de grabación
Estimación de plazos	8 sesiones

3.5 Alineación con ODS

Nuestra investigación se alinea directamente con la Agenda 2030 de las Naciones Unidas, impactando de forma teórica en dos Objetivos de Desarrollo Sostenible (ODS) fundamentales:

ODS 8 (Trabajo decente y crecimiento económico): Nuestro estudio cuantifica cómo la IA afecta a los salarios y al riesgo de automatización. Esto aporta conocimiento empírico para gestionar una transición tecnológica que proteja el empleo y fomente la productividad.


ODS 4 (Educación de calidad): Al analizar empíricamente la necesidad de adquirir nuevas competencias (*reskilling*), evidenciamos la urgencia de actualizar los programas formativos. El aprendizaje continuo es esencial para que los trabajadores mantengan su relevancia en el nuevo mercado laboral.

4. Calendario del proyecto

En este capítulo detallamos la planificación temporal de nuestro proyecto. Para garantizar el cumplimiento de los plazos, hemos organizado todas las tareas de forma cronológica. Además, justificamos esta planificación mediante técnicas de gestión de proyectos, como la estimación de tiempos y el cálculo de la ruta crítica.

4.1 Diagrama de Gantt

Para visualizar nuestra planificación, hemos diseñado un diagrama de Gantt. Esta herramienta muestra el orden y la duración de nuestras fases principales de trabajo. El cronograma abarca desde el inicio de la ingeniería de datos el 20 de enero hasta la entrega final del proyecto, fijada para el 16 de junio.



Para construir este diagrama de forma realista, hemos analizado matemáticamente las dependencias entre las tareas. Aplicando el Método de la Ruta Crítica (CPM), hemos calculado las fechas tempranas y tardías de cada actividad. Esto nos ha permitido identificar qué tareas tienen holgura cero y, por tanto, no admiten ningún retraso en nuestra planificación.

Para calcular el tiempo necesario para cada actividad, hemos utilizado el método PERT (Técnica de Revisión y Evaluación de Programas). Esta técnica nos ha permitido considerar la incertidumbre al estimar un tiempo optimista, un tiempo pesimista y un tiempo más probable para cada labor. Los resultados de nuestra estimación son los siguientes:

Gestión y Marco Administrativo

Planificación temporal y de recursos

Marco Teórico e investigación

Ingeniería y análisis de datos

Consolidación y entrega

2 sesiones = 1 semana

Actividad	Tiempo optimista	Tiempo pesimista	Tiempo probable	Tiempo estimado
Redacción del Acta de Constitución del proyecto	1 sesión	4 sesiones	2 sesiones	2 sesiones
Definición de requisitos MoSCOW y límites	1 sesión	4 sesiones	2 sesiones	2 sesiones
Elaboración de la EDT y su diccionario	3 sesiones	6 sesiones	4 sesiones	4 sesiones
Secuenciación. Traducción de la lista de tareas EDT	1 sesiones	4 sesiones	2 sesiones	2 sesiones
Estimación de duraciones mediante método	1 sesión	4 sesiones	2 sesiones	2 sesiones




Total estimado por bloques de trabajo Teniendo en cuenta que hay tareas realizándose simultáneamente, la carga de trabajo por bloques se distribuye de la siguiente manera:

- Gestión y Marco Administrativo: 10 sesiones
- Planificación temporal y de recursos: 4 sesiones

- Marco Teórico e investigación: 3 sesiones
- Ingeniería y análisis de datos: 8 sesiones
- Consolidación y entrega: 8 sesiones

Esto suma un total de 4 meses de trabajo, empezando el 2 de febrero y acabando el 2 de junio. Además, esta planificación nos permite dejar un margen de 2 semanas extra al final del cronograma para poder revisar el proyecto con calma y tener un colchón de seguridad por si surgieran retrasos o imprevistos



Actividades planteadas y organizadas mediante la EDT:

1. Gestión y Marco Administrativo (1.1 Redacción del Acta, 1.2 Requisitos MoSCoW, 1.3 EDT y Diccionario).
2. Planificación Temporal y de Recursos (2.1 Estimación PERT, 2.2 Diagrama de Precedencias, 2.3 Ruta Crítica CPM).
3. Marco Teórico e Investigación (3.1 Crítica al Estado del Arte, 3.2 Propuesta conceptual).
4. Ingeniería y Análisis de Datos (4.1 Limpieza en Python, 4.2 Correlaciones estadísticas, 4.3 Análisis de reskilling).
5. Consolidación y Entrega (5.1 Memoria final, 5.2 Visualizaciones, 5.3 Producción del vídeo).

Planteamiento de la planificación del trabajo:

- **1.3. Marco Teórico e Investigación:** Esta parte la dejamos acabada en 2 sesiones. Inicio Temprano: 9 febrero. Fin Temprano: 16 febrero. Inicio Tardío: 11 febrero. Fin Tardío: 18 febrero. Holgura: Cero holgura para esta parte ya que de ella depende el resto del trabajo.
- **2.4. Ingeniería y Análisis de Datos:** Acabamos esta parte con el tiempo suficiente para hacer la presentación de mitad cuatrimestre. Inicio Temprano: 18 febrero. Fin Temprano: 4 marzo. Inicio Tardío: 23 de febrero. Fin Tardío: 11 marzo. Holgura: Nos podemos permitir cierta holgura mínima pero innecesaria.
- **3.5.2. Creación de visualizaciones con citas integradas:** Tendremos espacio de sobra para poder montar y estudiar la presentación a realizar a mitad cuatrimestre con fecha el Miércoles 25 de marzo. Inicio Temprano: 9 marzo. Fin Temprano: 25 marzo. Inicio Tardío: 23 de marzo. Fin Tardío: 25 marzo. Holgura: Cero holgura ya que no podemos retrasar la presentación.
- **4.1. Gestión de las bases del proyecto y 2. Planificación Temporal:** La idea era empezar el primer día de vuelta de las vacaciones de Semana Santa, el 15 de abril, y terminar el 4 de mayo. Inicio Temprano: 15 de abril. Fin Temprano: 4 mayo. Inicio Tardío: 22 de abril. Fin Tardío: 10 mayo. Holgura: Sí que admite algún retraso pero es evitable.
- **5.5.1. Fusión de memoria final y 5.3. Redacción de guión y vídeo:** Parte final del proyecto en la que juntaremos toda la información y prepararemos la memoria final. Inicio Temprano: 15 de abril. Fin Temprano: 4 mayo. Inicio Tardío: 22 de abril. Fin Tardío: 10 mayo. Holgura: Sí que admite algún retraso pero es evitable.

4.2 Distribución de las tareas

Para maximizar la eficiencia del equipo antes de la fecha límite, hemos dividido el trabajo según los diferentes perfiles. Las labores de coordinación, control de requisitos y documentación recaen sobre la figura de la dirección de proyecto (*Project*

Manager). Por su parte, el desarrollo del código, la limpieza del *dataset* y las correlaciones estadísticas son responsabilidad principal del perfil de Ciencia de Datos (*Data Scientist*).

Por otro lado, la investigación del marco teórico y los cálculos matemáticos de la planificación temporal se han asignado al resto del equipo de analistas. Sin embargo, la consolidación de la memoria, la extracción de conclusiones y la producción del vídeo de presentación son responsabilidades transversales compartidas por todos los miembros del grupo.

5. Preparación y comprensión de datos

Este capítulo detalla el origen de la información utilizada en nuestra investigación. También explica el significado exacto de las variables principales que estructuran el análisis. Comprender estos datos de origen es fundamental para garantizar unos resultados precisos y fiables.

5.1 Conjunto de datos

Para realizar este proyecto, hemos seleccionado un conjunto de datos público y abierto. El archivo principal de trabajo se denomina `ai_impact_jobs_2010_2025.csv`. Hemos extraído este documento directamente de la plataforma Kaggle, en concreto de un repositorio especializado en el análisis de la sociedad y la Inteligencia Artificial.

Durante el proceso de preparación de datos se trabajó con dos versiones del conjunto de datos: la base original, formada por 5000 registros, y una versión procesada o GOLD, compuesta por 2830 registros tras aplicar criterios de limpieza y filtrado. En una primera versión de la base GOLD se conservaron únicamente las cinco industrias con mayor frecuencia en la muestra: Tech, Manufacturing, Agriculture, Retail y Healthcare. Esta decisión permitió trabajar con sectores suficientemente representados dentro del propio dataset, pero también supuso la exclusión de otras industrias presentes en la base original, como Finance, Government, Education y

Energy. En consecuencia, los resultados sectoriales deben interpretarse con cautela y no extrapolarse automáticamente al conjunto de sectores económicos.

Este *dataset* recopila información global sobre el mercado laboral tecnológico. Contiene miles de registros estructurados sobre ofertas de empleo, habilidades tecnológicas demandadas por las empresas y compensaciones económicas. El marco temporal de la muestra abarca ininterrumpidamente desde el año 2010 hasta el año 2025. Esta amplitud de quince años nos permite analizar tanto la evolución histórica como el impacto más reciente de la IA.

Para dar validez a nuestro estudio, partimos de varios supuestos sobre este conjunto de datos. Para el análisis se asume que el conjunto de datos permite estudiar patrones internos de la muestra, aunque no puede considerarse una representación completa ni libre de sesgos del mercado laboral mundial. Por tanto, los resultados deben interpretarse como tendencias observadas en el dataset utilizado y no como conclusiones extrapolables a todos los países, sectores o tipos de empleo.

5.2 Significado de los datos

El conjunto de datos está formado por múltiples columnas que aportan información específica sobre cada oferta de empleo. A continuación, definimos las variables más relevantes para nuestra investigación:

posting_year: Indica el año exacto en el que se publicó la oferta de trabajo en el mercado.

salary_usd: Representa el salario medio anual ofrecido para el puesto, expresado en dólares estadounidenses.

industry: Identifica el sector económico al que pertenece la empresa, como tecnología, salud o manufactura.

seniority_level: Clasifica el nivel de experiencia requerido para acceder al puesto (por ejemplo: Junior, Mid, Senior o Executive).

company_size: Indica el tamaño de la compañía que oferta el empleo, permitiendo diferenciar entre corporaciones y *startups*.

ai_skills: Enumera las habilidades técnicas concretas exigidas por el empleador, tales como *Machine Learning*, MLOps o Procesamiento de Lenguaje Natural.

ai_intensity_score: Mide numéricamente la intensidad de uso de herramientas de Inteligencia Artificial que requiere el trabajo diario.

automation_risk_score: Cuantifica la probabilidad de que las tareas del puesto sean automatizadas. Valores superiores a 0,7 indican un riesgo alto.

ai_job_displacement_risk: Evalúa el riesgo específico de que un trabajador sea desplazado o sustituido por algoritmos.

reskilling_required: Es una variable booleana (Verdadero/Falso). Indica si el empleado necesita adquirir nueva formación de forma obligatoria para adaptarse a la tecnología.

5.3 Limpieza y transformación de datos

En primer lugar, el *dataset* fue cargado desde el archivo CSV original y realizamos la conversión de las variables numéricas relevantes (*salary_usd* y *automation_risk_score*) mediante la función `pd.to_numeric()`, utilizando el parámetro `errors="coerce"` para transformar automáticamente valores inválidos en nulos (NaN).

Posteriormente, aplicamos un proceso de imputación de valores nulos basado en la mediana por industria. Esta técnica nos permite mantener la distribución de los datos y evitar sesgos provocados por valores extremos. La imputación se realizó agrupando los registros según la variable *industry* y reemplazando los valores faltantes por la mediana del grupo correspondiente.

Para la detección y eliminación de valores atípicos (*outliers*), utilizamos el método estadístico del Rango Intercuartílico (IQR). Este procedimiento se aplicó tanto sobre la variable *salary_usd* como sobre *automation_risk_score*, eliminando los registros que quedaban fuera de los límites estadísticos establecidos.

Finalmente, realizamos una transformación de la variable *ai_skills*, separando las habilidades contenidas en una misma celda mediante la técnica de *split* y posterior expansión, permitiéndonos así analizar individualmente cada habilidad relacionada con inteligencia artificial.

6. Conocimiento extraído

En este capítulo transformamos los datos procesados en conocimiento útil. Nuestro objetivo es dar respuesta a las hipótesis planteadas al inicio de la investigación. Para ello, detallamos los métodos analíticos empleados y las herramientas tecnológicas utilizadas. Finalmente, exponemos los resultados obtenidos tras evaluar el impacto de la Inteligencia Artificial en el mercado laboral.

6.1 Metodología

Para extraer este conocimiento, hemos aplicado un enfoque analítico y cuantitativo. Nuestra metodología estadística se basa en resolver los cuatro objetivos principales del proyecto aplicando las siguientes técnicas:

Imputación de nulos (Mediana por industria): Cada valor nulo de *salary_usd* se sustituye por la mediana salarial de su propia industria. Lo mismo ocurre con *automation_risk_score*. Esto se ve reflejado en el código de la siguiente forma:

```
df.groupby("industry")["salary_usd"].transform(lambda x: x.fillna(x.median()))
df.groupby("industry")["automation_risk_score"].transform(lambda x:
x.fillna(x.median()))
```

Tratamiento de valores atípicos (Outliers con IQR): Para limpiar los extremos, calculamos los cuartiles y establecemos los límites superiores e inferiores:

$Q1 = \text{data}[\text{column}].\text{quantile}(0.25)$

$Q3 = \text{data}[\text{column}].\text{quantile}(0.75)$

$IQR = Q3 - Q1$

$\text{lower} = Q1 - 1.5 * IQR$

$\text{upper} = Q3 + 1.5 * IQR$

Correlación de Pearson: Para medir la relación estadística, la librería Pandas lo calcula automáticamente estableciendo como variable X nuestro *ai_intensity_score* y como variable Y el *salary_usd*.

Segmentación de datos: Finalmente, la segmentación la hemos realizado mediante la función `.groupby` en las variables de interés, a excepción de una (Segmentación porcentual por *seniority*). En esta última, generamos una tabla que cruza dos variables categóricas para analizar cómo se distribuyen entre sí.

6.2 Herramientas

Todo el procesamiento técnico se realizó con Python. Usamos Pandas para cargar, limpiar, transformar y agrupar los datos. Usamos NumPy para apoyar los cálculos numéricos.

También preparamos el proyecto para generar gráficos con Matplotlib y WordCloud. Estas librerías nos permitieron representar la evolución temporal, comparar grupos y visualizar las habilidades técnicas más frecuentes.

Durante la fase exploratoria trabajamos con Jupyter Notebook. En la fase final organizamos el código en un script estructurado llamado `src/analysis_pipeline.py`. Este archivo permite reproducir el proceso completo desde la base original hasta los resultados finales.

El script genera una base limpia revisada, tablas CSV, gráficos y un resumen técnico. De esta forma, el análisis puede ser auditado y ejecutado de nuevo desde el repositorio de GitHub.

6.3 Resultados descriptivos principales

A continuación, se presentan los principales resultados obtenidos a partir de la versión GOLD del conjunto de datos, compuesta por 2.830 registros. El objetivo de este apartado es mostrar de forma resumida la evidencia estadística utilizada para

responder a los objetivos del proyecto. Todas las tablas recogen datos agregados, por lo que los resultados deben interpretarse como patrones observados dentro de la muestra analizada y no como relaciones causales directas.

6.3.1 Asociación entre presencia de IA y salario ofertado

En primer lugar, se comparó el salario medio ofertado entre las ofertas que mencionan IA (ai_mentioned = True) y aquellas que no la mencionan (ai_mentioned = False). Como se observa en la Tabla 1, las ofertas con mención de IA presentan un salario medio superior dentro de la muestra analizada.


Tabla 1. Salario medio ofertado según mención de IA en la versión GOLD del dataset.

Tabla 1. Salario medio ofertado según mención de IA

Mención de IA (ai_mentioned)	Nº de ofertas	Salario medio (salary_usd)	Mediana salarial
False	1.945	53.250,22	55.151
True	885	82.331,61	85.705

La diferencia observada entre ambos grupos es de 29.081,39 dólares en salario medio. Esto supone que, dentro de la muestra, las ofertas con mención de IA presentan un salario medio aproximadamente un 54,6 % superior al de las ofertas sin mención de IA. No obstante, este resultado debe interpretarse como una asociación estadística y no como una relación causal directa.

Figura 1. Salario medio ofertado según mención de IA.



Para complementar esta comparación, se calcularon los coeficientes de correlación de Pearson y Spearman entre la variable `ai_intensity_score` y el salario ofertado (`salary_usd`). Los resultados se muestran en la **Tabla 2**.

Tabla 2. Correlación entre intensidad de IA y salario ofertado.

Tabla 2. Correlación entre intensidad de IA y salario ofertado

Método de correlación	Coefficiente	Interpretación	Significación
Pearson	0,402	Asociación positiva moderada	$p < 0,001$
Spearman	0,306	Asociación positiva débil-moderada	$p < 0,001$

Ambos coeficientes son positivos, lo que indica que, en la muestra analizada, una mayor intensidad de IA tiende a estar asociada con salarios más elevados. Sin embargo, la magnitud de la relación no permite afirmar causalidad.

6.3.2 Riesgo de automatización por industria

El segundo bloque de análisis se centra en el riesgo de automatización por sector industrial. Para ello, se calculó la media de `automation_risk_score` y el porcentaje de

ofertas que superan el umbral de alto riesgo definido en el proyecto (automation_risk_score > 0,7).

Tabla 3. Riesgo de automatización por industria en la versión GOLD del dataset.

Tabla 3. Riesgo de automatización por industria

Industria	Nº de ofertas	Media de automation_risk_score	% de ofertas con riesgo > 0,7
Agriculture	567	0,620	50,6 %
Healthcare	557	0,612	45,2 %
Manufacturing	569	0,608	44,6 %
Retail	564	0,599	46,8 %
Tech	573	0,525	34,4 %

Los resultados muestran diferencias entre industrias. Agriculture presenta la media más alta de riesgo de automatización y también el mayor porcentaje de ofertas por encima del umbral de 0,7. En cambio, Tech presenta la media más baja de automation_risk_score dentro de las cinco industrias conservadas en la versión GOLD. Estos resultados deben interpretarse teniendo en cuenta que la base procesada conserva únicamente las industrias más frecuentes, por lo que no representan necesariamente el comportamiento de todos los sectores económicos.

Figura 2. Media de riesgo de automatización por industria.





Figura 3. Porcentaje de ofertas con riesgo de automatización superior a 0,7 por industria.



6.3.3 Riesgo de desplazamiento por nivel de experiencia

También se analizó la distribución de la variable `ai_job_displacement_risk` según el nivel de experiencia profesional (`seniority_level`). La Tabla 4 muestra la distribución cruzada entre ambas variables.

Tabla 4. Distribución del riesgo de desplazamiento por IA según nivel de experiencia.

Tabla 4. Riesgo de desplazamiento por nivel de experiencia


Nivel de experiencia	Nº de ofertas	High	Medium	Low	Media de automation_risk_score
Executive	490	131 (26,7 %)	188 (38,4 %)	171 (34,9 %)	0,601
Intern	442	157 (35,5 %)	136 (30,8 %)	149 (33,7 %)	0,589
Junior	476	155 (32,6 %)	172 (36,1 %)	149 (31,3 %)	0,591
Lead	463	137 (29,6 %)	161 (34,8 %)	165 (35,6 %)	0,611
Mid	463	165 (35,6 %)	139 (30,0 %)	159 (34,3 %)	0,596
Senior	496	153 (30,8 %)	168 (33,9 %)	175 (35,3 %)	0,568

Los resultados no permiten afirmar de forma concluyente que los perfiles junior sean los más vulnerables dentro de la muestra. Aunque el porcentaje de ofertas junior clasificadas como High es relevante, otros niveles como Intern y Mid presentan porcentajes similares o superiores. Además, las medias de `automation_risk_score` por



nivel de experiencia son relativamente próximas entre sí. Por tanto, este análisis debe interpretarse de forma prudente y exploratoria.

Figura 4. Distribución del riesgo de desplazamiento por IA según nivel de experiencia.



6.3.4 Relación entre `reskilling_required` y `ai_mentioned`

Por último, se analizó la relación entre la variable `reskilling_required` y la variable `ai_mentioned`. La Tabla 5 muestra que ambas variables coinciden exactamente en la versión GOLD del dataset.

Tabla 5. Tabla cruzada entre `ai_mentioned` y `reskilling_required`.


Tabla 5. Tabla cruzada entre `ai_mentioned` y `reskilling_required`

ai_mentioned	reskilling_required = False	reskilling_required = True	Total
False	1.945	0	1.945
True	0	885	885
Total	1.945	885	2.830

La coincidencia entre ambas variables es total: las 885 ofertas que mencionan IA tienen `reskilling_required` = True, mientras que las 1.945 ofertas que no mencionan IA tienen `reskilling_required` = False. Por tanto, `reskilling_required` no debe interpretarse

como una variable independiente respecto a `ai_mentioned`. En este dataset, la variable de capacitación profesional funciona como un indicador derivado o altamente dependiente de la mención de IA. En consecuencia, no puede afirmarse que el análisis demuestre de forma independiente que la IA aumente la necesidad de reskilling; únicamente se observa cómo está codificada esta relación dentro de la muestra utilizada.

Figura 5. Relación entre mención de IA y necesidad de reskilling.



6.4 Análisis de vulnerabilidad por nivel de experiencia

Para analizar la posible vulnerabilidad de los perfiles con menor experiencia, se comparó la variable `ai_job_displacement_risk` con el nivel de experiencia profesional (`seniority_level`). Además, se comprobó si las categorías de riesgo de desplazamiento por IA estaban alineadas con la variable numérica `automation_risk_score`. Esta comprobación es necesaria porque ambas variables no miden exactamente lo mismo: `automation_risk_score` representa una puntuación numérica de riesgo de automatización, mientras que `ai_job_displacement_risk` clasifica las ofertas en categorías cualitativas: Low, Medium y High.

La revisión de los datos muestra que las categorías de `ai_job_displacement_risk` no presentan diferencias claras en sus medias de `automation_risk_score`. En la versión GOLD del dataset, las ofertas clasificadas como High tienen una media de `automation_risk_score` de 0,590; las clasificadas como Low presentan una media de 0,591; y las clasificadas como Medium alcanzan una media de 0,597. Por tanto, no puede afirmarse que la categoría High esté asociada a un mayor riesgo numérico de automatización dentro de este conjunto de datos.

Nivel de experiencia	Nº de ofertas	Media de <code>automation_risk_score</code>	% High en <code>ai_job_displacement_risk</code>	% Medium	% Low
Executive	490	0,601	26,7 %	38,4 %	34,9 %
Intern	442	0,589	35,5 %	30,8 %	33,7 %
Junior	476	0,591	32,6 %	36,1 %	31,3 %
Lead	463	0,611	29,6 %	34,8 %	35,6 %
Mid	463	0,596	35,6 %	30,0 %	34,3 %
Senior	496	0,568	30,8 %	33,9 %	35,3 %

Riesgo de automatización y desplazamiento por nivel de experiencia en la versión GOLD del dataset.

A partir de estos resultados, no se observa una diferencia suficientemente clara para afirmar que los perfiles junior sean los más vulnerables según los datos analizados. Aunque la literatura revisada advierte de una posible exposición mayor de los perfiles de entrada a la automatización de tareas básicas, los datos de este proyecto no permiten confirmar esa hipótesis de forma robusta. En la muestra GOLD, el porcentaje de ofertas junior clasificadas como High en `ai_job_displacement_risk` es del 32,6 %, un valor próximo al de otros niveles de experiencia e inferior al observado en perfiles Intern y Mid. Por tanto, este objetivo debe interpretarse como un análisis exploratorio que no confirma de forma concluyente una mayor vulnerabilidad de los perfiles junior.

7. Validación y despliegue

En este capítulo comprobamos la solidez de nuestros resultados fuera del entorno inicial de pruebas. Es fundamental asegurar que los modelos analíticos funcionen correctamente con información nueva y diferente a la original. Además, detallamos cómo hemos estructurado nuestro código para que otros investigadores puedan revisarlo, utilizarlo y replicar nuestro estudio.

7.1 Uso de otro conjunto de datos. Encuestas.

Nuestra investigación tiene un enfoque teórico y analítico. Por este motivo, no realizamos encuestas propias ni trabajo de campo con usuarios.

Para validar la solidez de los resultados, comparamos la base original `ai_impact_jobs_2010_2025.csv` con la base limpia generada por nuestro pipeline, `outputs/ai_impact_jobs_2010_2025_GOLD_REVISED.csv`.

Esta comparación nos permitió comprobar que las tendencias principales se mantenían después de aplicar el tratamiento de nulos y la eliminación de outliers.

También nos permitió revisar si la limpieza modificaba de forma excesiva la estructura inicial de los datos.

Además, en la versión revisada de la base limpia conservamos todas las industrias disponibles. Esta decisión mejora la representatividad respecto a la primera versión GOLD, que solo mantenía las cinco industrias más frecuentes.

Por tanto, la validación técnica se basó en comprobar la coherencia entre la base original y la base procesada. No presentamos estos archivos como dos conjuntos de datos independientes, sino como dos fases del mismo proceso de análisis.

7.2 Repositorio reproducible

El despliegue del proyecto no consiste en una aplicación móvil ni en una página web comercial. Nuestro producto final es un repositorio público con código reproducible en Python.

En el repositorio hemos organizado los scripts necesarios para limpiar la base de datos, calcular los indicadores principales y generar las visualizaciones. El archivo principal es `src/analysis_pipeline.py`. Este script parte del dataset original `ai_impact_jobs_2010_2025.csv` y genera automáticamente la base limpia revisada, las tablas de resultados y los gráficos finales.

El repositorio permite que el profesor y el tribunal auditen el proceso completo. También permite ejecutar de nuevo el análisis en otro ordenador siguiendo las instrucciones del archivo [README.md](#).

El código final del proyecto se encuentra publicado en el repositorio anterior. El archivo principal es `src/analysis_pipeline.py`, desde donde se puede reproducir la limpieza, el análisis y la generación de resultados.

Enlace al repositorio:

<https://github.com/claudiacaarbo/Proyecto>

8. Conclusiones

El presente proyecto ha analizado la evolución del empleo ante la expansión de la Inteligencia Artificial durante el periodo 2010-2025, a partir de una muestra internacional de ofertas de empleo. El objetivo principal ha sido estudiar la relación entre la presencia de competencias de IA, los salarios ofertados, el riesgo de automatización, el nivel de experiencia profesional y la necesidad de recapacitación laboral o *reskilling*. Para ello, se ha llevado a cabo un proceso de limpieza, transformación y análisis de datos mediante Python, aplicando técnicas descriptivas y estadísticas.

En relación con el primer objetivo, los resultados muestran una asociación positiva entre la intensidad de uso de IA y el salario medio ofertado. Esto significa que los puestos con mayor presencia de competencias relacionadas con IA tienden a presentar salarios medios superiores dentro de la muestra analizada. No obstante, esta relación debe interpretarse como una asociación estadística y no como una relación causal directa, ya que el análisis realizado no permite afirmar que la IA sea por sí sola la causa del incremento salarial.

Respecto al riesgo sectorial, el análisis ha permitido identificar diferencias relevantes entre industrias en función del nivel de automatización observado. Los sectores con mayor presencia de tareas repetitivas o más fácilmente automatizables presentan valores superiores de riesgo de automatización. Sin embargo, estos resultados deben interpretarse teniendo en cuenta las características del conjunto de datos utilizado y el filtrado aplicado en la versión procesada, ya que no todos los sectores económicos están representados con la misma intensidad.

En cuanto a la vulnerabilidad por nivel de experiencia, el análisis realizado no permite confirmar de forma concluyente que los perfiles junior sean los más expuestos al desplazamiento tecnológico dentro de la muestra analizada. Aunque el estado del arte señala una posible mayor vulnerabilidad de los perfiles de entrada, los resultados obtenidos en la versión GOLD del dataset muestran diferencias reducidas entre niveles de experiencia. Además, la variable `ai_job_displacement_risk` no está claramente alineada con `automation_risk_score`, ya que las categorías Low, Medium y High presentan medias de riesgo de automatización muy similares. Por tanto, este objetivo debe interpretarse como un resultado exploratorio: los datos permiten

comparar la distribución del riesgo por seniority, pero no sostienen una conclusión fuerte sobre una mayor vulnerabilidad específica de los perfiles junior.

En relación con la adaptación y recapacitación profesional, debe señalarse una limitación específica de la variable *reskilling_required*. En la versión GOLD del conjunto de datos, esta variable coincide exactamente con la variable *ai_mentioned*: 885 ofertas presentan simultáneamente ambas variables con valor True, mientras que 1945 ofertas presentan ambas con valor False. Por este motivo, la necesidad de *reskilling* no debe interpretarse como un hallazgo independiente que demuestre que la IA aumenta directamente la recapacitación profesional. En este dataset, la variable de *reskilling* está directamente asociada a la mención de IA, por lo que debe entenderse como un indicador derivado o altamente dependiente de dicha mención. En consecuencia, los resultados relacionados con *reskilling* deben interpretarse con cautela y como una característica interna del conjunto de datos analizado, no como evidencia externa de una relación causal entre IA y necesidad de formación continua.

En conjunto, los resultados obtenidos permiten afirmar que la Inteligencia Artificial se relaciona con cambios relevantes en el mercado laboral analizado, especialmente en términos de salarios, riesgo de automatización y transformación de competencias. No obstante, el alcance del estudio es exploratorio y se limita a los datos disponibles. Por tanto, las conclusiones deben entenderse como patrones observados dentro de la muestra, no como afirmaciones generalizables a la totalidad del mercado laboral mundial.

La principal limitación del estudio es la dependencia de un único conjunto de datos público. Aunque la base original presenta cobertura internacional y diversidad sectorial, la versión procesada utilizada en el análisis reduce el número de registros y prioriza las industrias más frecuentes. Esta decisión mejora la estabilidad estadística de los sectores analizados, pero reduce la representatividad del conjunto final. En particular, la exclusión de algunos sectores presentes en la base original limita la posibilidad de comparar el comportamiento de todas las industrias. Asimismo, otra limitación metodológica relevante es que la variable *reskilling_required* no actúa como una variable independiente respecto a *ai_mentioned*, ya que ambas coinciden exactamente en la versión GOLD del dataset. Asimismo, el análisis por nivel de experiencia presenta una limitación específica: la variable *ai_job_displacement_risk* no muestra una correspondencia clara con *automation_risk_score*, por lo que las conclusiones sobre vulnerabilidad de perfiles junior deben formularse con especial prudencia.

9. Bibliografía

Acemoglu, D., & Autor, D. H. (2011). *Skills, tasks and technologies: Implications for employment and earnings*. En O. Ashenfelter y D. Card (Eds.), *Handbook of Labor Economics* (Vol. 4B, pp. 1043-1171). Elsevier. DOI: 10.1016/S0169-7218(11)02410-5.

Acemoglu, D., Autor, D. H., & Johnson, S. (2026). *Building Pro-Worker Artificial Intelligence*. National Bureau of Economic Research, Working Paper No. 34854.

Brynjolfsson, E., Chandar, B., & Chen, R. (2025). *Canaries in the Coal Mine? Six Facts about the Recent Employment Effects of Artificial Intelligence*. Stanford Digital Economy Lab.

Fondo Monetario Internacional. (2024). *La economía mundial transformada por la inteligencia artificial ha de beneficiar a la humanidad*. Fondo Monetario Internacional.

Foro Económico Mundial. (2025). *The Future of Jobs Report 2025*. World Economic Forum.

Frey, C. B., & Osborne, M. A. (2013). *The Future of Employment: How Susceptible Are Jobs to Computerisation?* Oxford Martin School, University of Oxford.

Kaggle. (2025). *Global AI Impact on Jobs (2010-2025)* [Conjunto de datos]. Kaggle.

PwC. (2025). *The Fearless Future: 2025 Global AI Jobs Barometer*. PricewaterhouseCoopers.

10. Anexos

Anexo A. Repositorio del proyecto

El código fuente, los datos procesados y los scripts utilizados durante el desarrollo del proyecto se encuentran disponibles en el repositorio de GitHub del equipo:

Enlace al repositorio:

El repositorio se ha organizado con el objetivo de facilitar la reproducibilidad del análisis. En él se incluyen los archivos de datos, los notebooks de procesamiento, los scripts de análisis estadístico y las visualizaciones generadas durante el proyecto.

Anexo B. Estructura del repositorio

acabar

Anexo C. Diccionario de variables

Variable	Descripción	Tipo de dato
<code>job_title</code>	Nombre o título del puesto de trabajo.	Texto
<code>industry</code>	Sector o industria al que pertenece la oferta.	Categórica
<code>salary_usd</code>	Salario ofertado expresado en dólares estadounidenses.	Numérica
<code>year</code>	Año asociado al registro de la oferta.	Numérica
<code>seniority_level</code>	Nivel de experiencia profesional del puesto.	Categórica
<code>ai_mentioned</code>	Indica si la oferta menciona explícitamente IA.	Booleana

<code>ai_intensity_score</code>	Puntuación que representa la intensidad de uso o presencia de IA en la oferta.	Numérica
<code>automation_risk_score</code>	Puntuación asociada al riesgo de automatización del puesto.	Numérica
<code>ai_job_displacement_risk</code>	Categoría cualitativa de riesgo de desplazamiento por IA.	Categórica
<code>reskilling_required</code>	Indica si la oferta aparece marcada como relacionada con necesidad de capacitación profesional.	Booleana
<code>ai_skills</code>	Lista de habilidades o competencias relacionadas con IA.	Texto

Anexo D. Resumen del proceso de limpieza

Fase del proceso	Nº de registros	Descripción
Dataset original	5.000	Registros iniciales descargados desde Kaggle.
Registros eliminados o filtrados	2.170	Registros descartados durante la limpieza, tratamiento de valores atípicos o filtrado sectorial.

Dataset GOLD final	2.830	Registros finales utilizados en el análisis principal.
--------------------	-------	--

Durante el proceso de limpieza se trataron valores nulos, se revisaron valores atípicos y se generó una versión procesada del conjunto de datos, denominada GOLD. Esta versión permitió trabajar con datos más consistentes, aunque también redujo la cobertura sectorial del análisis. Por ello, los resultados deben interpretarse como patrones observados dentro de la muestra final y no como conclusiones generalizables a todo el mercado laboral.

Anexo E. Scripts y notebooks utilizados

Archivo	Función principal
<code>Claudia Proyecto.ipynb</code>	Notebook principal de limpieza, transformación y análisis exploratorio.
<code>cleaning_data.py</code>	Script de limpieza de datos, tratamiento de valores nulos y detección de valores atípicos.
<code>eda_analysis.py</code>	Script de análisis descriptivo y generación de tablas agregadas.
<code>salary_ai_analysis.py</code>	Análisis de la asociación entre intensidad de IA y salario ofertado.
<code>automation_risk_analysis.py</code>	Análisis del riesgo de automatización por industria.
<code>seniority_risk_analysis.py</code>	Análisis cruzado entre nivel de experiencia y riesgo de desplazamiento por IA.
<code>reskilling_analysis.py</code>	Comparación entre <code>reskilling_required</code> y <code>ai_mentioned</code> .

`visualizations.py`

Generación de gráficos incluidos en la memoria y la presentación.

Anexo F. Reproducibilidad del análisis

acabar